

Analyse du nombre de calories brûlées

À compléter

Table des matières

1 Étude du nombre de calories brûlées	1
1.1 Modélisation à partir des variables quantitatives	1
1.2 Effet des variables qualitatives : niveau et type de sport	3
1.3 Sélection de modèle à l'aide du critère BIC	4

1 Étude du nombre de calories brûlées

Cette partie vise à modéliser le nombre de calories brûlées au cours d'une séance d'entraînement en fonction des variables explicatives disponibles.

1.1 Modélisation à partir des variables quantitatives

Nous ajustons un modèle de **régression linéaire multiple** reliant le nombre de calories brûlées aux variables quantitatives du jeu de données.

$$\text{Calories}_i = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{weight}_i + \beta_3 \text{height}_i + \beta_4 \text{bpm_ave}_i + \beta_5 \text{duration}_i + \beta_6 \text{fat}_i + \beta_7 \text{water}_i + \beta_8 \text{freq}_i + \beta_9 \text{bmi}_i + \varepsilon_i$$

Dans la Figure 1, les résidus sont globalement centrés autour de zéro, ce qui valide l'hypothèse d'espérance nulle des erreurs. Le Q-Q plot indique une déviation modérée à la normalité dans les queues, et le graphique « Scale-Location » suggère une légère hétéroscédasticité, sans observation fortement influente. En ajoutant des interactions, on voit dans la Figure 2 que cela permet d'améliorer la qualité des résidus, notamment en réduisant la courbure observée précédemment. Cependant, ce modèle devient très complexe, avec un grand nombre de paramètres, ce qui peut conduire à du sur-ajustement. Cela justifie l'utilisation d'une méthode de sélection de variables afin d'obtenir un modèle plus simple et plus interprétable.




FIGURE 1 – Résidus du modèle linéaire quantitatif




FIGURE 2 – Résidus du modèle linéaire quantitatif avec interactions

1.2 Effet des variables qualitatives : niveau et type de sport

Nous étudions l'effet du niveau d'expérience et du type de sport sur les calories brûlées à l'aide d'une **ANOVA à deux facteurs avec interaction**.

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}, \quad \begin{cases} i = 1, \dots, I \\ j = 1, \dots, J \\ k = 1, \dots, n_{ij} \end{cases}$$



FIGURE 3 – Calories brûlées selon le niveau d'expérience et le type de sport

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
level	2	36801094	18400547	504.827	<2e-16 ***
type	3	134164	44721	1.227	0.299
level:type	6	289090	48182	1.322	0.244
Residuals	961	35027713	36449		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

La Figure 3 montre une augmentation nette du nombre de calories brûlées avec le niveau d'expérience, quel que soit le type de sport pratiqué. L'ANOVA confirme un effet significatif du niveau ($p < 2 \times 10^{-16}$), tandis que l'effet du type de sport n'est pas significatif. De plus, l'interaction entre le niveau et le type de sport n'est pas significative, ce qui indique que l'influence du niveau sur les calories brûlées est similaire pour tous les types de sport.




FIGURE 4 – Sélection des variables explicatives par le critère BIC.

1.3 Sélection de modèle à l'aide du critère BIC

Nous considérons un modèle complet incluant toutes les variables explicatives, correspondant à une **ANCOVA**.

La Figure 4 illustre la sélection des variables explicatives par le critère BIC, qui privilégie des modèles parcimonieux. On observe que seules certaines variables sont retenues de manière stable, tandis que d'autres sont fréquemment exclues, ce qui traduit leur faible contribution explicative ou une redondance avec d'autres variables. Le meilleur modèle est $Y_i = \theta_0 + \theta_1 x_{\text{age},i} + \theta_2 x_{\text{bpm_vae},i} + \theta_3 x_{\text{duration},i} + \beta 1_{\text{gender=male},i}$.

Analysis of Variance Table

Model 1: calories ~ age + gender + bpm_ave + duration

Model 2: calories ~ age + gender + weight + height + bpm_ave + duration +
fat + water + freq + bmi + type + level

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	968	1522442				
2	957	1499223	11	23219	1.3474	0.1929

Un test de sous modèle avec le modèle complet nous donne une p-valeur de 0.2, ce qui nous permet d'accepter le sous-modèle.

La Figure 5 montre que les résidus du modèle sélectionné par le BIC sont globalement centrés autour de zéro, ce qui indique une absence de biais. Cependant, une légère non-linéarité apparaît dans la relation entre les résidus et les valeurs ajustées, avec une dispersion plus marquée pour les valeurs ajustées extrêmes.




FIGURE 5 – Résidus en fonction des valeurs ajustées pour le modèle sélectionné par BIC.

Cette forme suggère la présence d’une hétéroscédasticité modérée sans remettre en cause la pertinence globale du modèle dans le cadre de cette étude.