

Analyse du nombre de calories brûlées

Ilias Bouhalla, Chaima Sghir, Brice Vergnou

Table des matières

1	Introduction	1
2	Analyse descriptive	1
2.1	Variables qualitatives	2
2.2	Variables quantitatives	2
2.2.1	Distribution de l'âge, du BMI et des calories brûlées	2
2.3	Calories selon le type et le niveau	2
2.4	Corrélations et relations bivariées	2

1 Introduction

Ce projet a pour objectif d'analyser les facteurs influençant la dépense énergétique lors de séances sportives à partir d'un jeu de données décrivant les caractéristiques physiques, physiologiques et les pratiques d'adhérents d'une salle de sport. Après une analyse descriptive et exploratoire du jeu de données, nous mobilisons des tests d'hypothèses, des méthodes de clustering et différentes approches de modélisation statistique afin d'étudier le nombre de calories brûlées et le niveau d'expérience des pratiquants. Une attention particulière est portée à la sélection de variables, à l'interprétation des modèles et à l'analyse des résidus, dans une logique d'aller-retour entre exploration et modélisation.

2 Analyse descriptive

TABLE 1 – Aperçu des premières lignes du jeu de données

age	gender	weight	height	bpm_ave	duration	calories	type	fat	water	freq	level	bmi
56	Male	88.3	1.71	157	1.69	1313	Yoga	12.6	3.5	4	3	30.20
46	Female	74.9	1.53	151	1.30	883	HIIT	33.9	2.1	4	2	32.00
32	Female	68.1	1.66	122	1.11	677	Cardio	33.4	2.3	4	2	24.71
25	Male	53.2	1.70	164	0.59	532	Strength	28.8	2.1	3	1	18.41
38	Male	46.1	1.79	158	0.64	556	Strength	29.2	2.8	3	1	14.39
56	Female	58.0	1.68	156	1.59	1116	HIIT	15.5	2.7	5	3	20.55
36	Male	70.3	1.72	169	1.49	1385	Cardio	21.3	2.3	3	2	23.76
40	Female	69.7	1.51	141	1.27	895	Cardio	30.6	1.9	3	2	30.57
28	Male	121.7	1.94	127	1.03	719	Strength	28.9	2.6	4	2	32.34
28	Male	101.8	1.84	136	1.08	808	Cardio	29.7	2.7	3	1	30.07

2.1 Variables qualitatives

On en a quatre : `type`, `level`, `gender`, `freq`. Même si certaines d'entre elles sont données comme numériques, nous préférons les traiter comme variable qualitative car elles se comportent comme des groupes distincts.

La Figure 1 montre la répartition des types d'exercices selon le genre et montre qu'on ne voit pas de différence significative dans la pratique sportive .




FIGURE 1 – Répartition du type d'exercice selon le genre (proportions en colonne).

2.2 Variables quantitatives

2.2.1 Distribution de l'âge, du BMI et des calories brûlées

La Figure 2 illustre la distribution de trois variables importantes :

- l'âge des participants,
- leur indice de masse corporelle (BMI),
- ainsi qu'un boxplot des calories brûlées.

On voit que pour pouvoir manipuler ces données avec des méthodes comme l'ACP nous devrons plus tard normaliser nos données car celles-ci ne sont pas à la même échelle et ne suivent pas toutes une loi normale.

2.3 Calories selon le type et le niveau

La Figure 3 permet de visualiser l'influence du type d'exercice et du niveau.

Les distributions montrent que les calories brûlées varient fortement selon le type d'exercice et le niveau : les pratiquants de niveau élevé ainsi que certains types d'entraînement plus intenses présentent des valeurs médianes plus hautes. La dispersion importante à l'intérieur de chaque groupe suggère toutefois une forte variabilité individuelle. La fréquence d'entraînement apparaît également liée à un accroissement global des calories. Ces observations indiquent que les facteurs qualitatifs influencent bien la dépense énergétique, ce qui justifie de les intégrer dans les modèles explicatifs.

2.4 Corrélations et relations bivariées

Enfin, la Figure 4 affiche les corrélations entre 2 paramètres.

La matrice de corrélation révèle des relations attendues : une forte association entre poids, BMI et masse grasse, et une corrélation positive marquée entre durée d'exercice, fréquence cardiaque et calories brûlées. Ces liens suggèrent que plusieurs variables décrivent des informations redondantes, ce qui justifie éventuellement une réduction dimensionnelle.




FIGURE 2 – Histogrammes de l'âge et du BMI, et boxplot des calories brûlées.




FIGURE 3 – Calories brûlées selon le type d'exercice (à gauche) et le niveau (à droite).

(ACP) ou une sélection de variables dans les modèles. On observe aussi des variables quasi indépendantes, utiles pour compléter l'explication du phénomène sans colinéarité excessive.




FIGURE 4 – Matrice de corrélation des variables quantitatives.