

Clustering des individus

Cette section vise à regrouper les individus de l'étude en groupes homogènes (clusters). L'analyse repose sur les variables quantitatives de notre jeu de données. Les variables qualitatives (gender, type, level, freq) ont été écartées de la construction des classes.

Pour garantir une segmentation robuste, nous avons exploré plusieurs algorithmes de classification sur les données préalablement centrées et réduites. Cette normalisation est cruciale pour que les variables à forte variance (comme les calories) ne dominent pas le calcul des distances par rapport aux variables à faible amplitude (comme la taille).

Classification Ascendante Hiérarchique (CAH) : Utilisée en première approche avec la distance euclidienne et le critère de Ward. Ce critère minimise la perte d'inertie inter-classe à chaque étape de regroupement, favorisant des classes compactes. Elle nous permet aussi de visualiser la structure des données via un dendrogramme.

K-Means : Cet algorithme itératif réalloue les individus pour minimiser l'inertie intra-classe totale.

Mélanges gaussiens : Approche probabiliste modélisant les données par une superposition de lois normales. Elle permet de s'adapter à des formes et volumes de classes variés (via la covariance) et d'estimer une probabilité d'appartenance pour chaque individu.

K-means

Une première approche naturelle pourrait être d'essayer de minimiser l'inertie intra-classe en utilisant un algorithme des K-means. Pour connaître le nombre de classes optimales, on utilise deux critères.

Courbe d'inertie : On observe une cassure ("coude") à $K = 3$ sur la Figure 1, indiquant que l'ajout d'un quatrième groupe n'apporte pas une baisse significative de l'inertie intra-classe.

Silhouette moyenne : Le score atteint son maximum global pour $K = 3$ sur la Figure 1, confirmant que les individus sont, en moyenne, bien mieux classés dans une structure à trois classes.

Classification hiérarchique

Une seconde approche explorée est celle d'un modèle de classification emboîté (CAH). Cette méthode a été privilégiée pour sa capacité à révéler l'architecture structurelle des données sans imposer de nombre de classes a priori. Le choix du nombre de groupes K repose sur plusieurs critères : l'analyse du dendrogramme et le critère de Calinski-Harabasz.

La Figure 2 synthétise ces indicateurs. Le dendrogramme met en évidence une perte d'inertie très significative lors du passage de 3 à 2 classes, suggérant que la partition en 3 groupes est la plus naturelle. Cette observation est corroborée par l'indicateur de Calinski-Harabasz, on observe un maximum du critère à 3 classes.




FIGURE 1 : Méthode du coude et Silhouette




FIGURE 2 : **Critères de sélection du nombre de classes.** Gauche : Dendrogramme de la CAH. Droite : Méthode de Calinski-Harabasz.

On remarque la classification issus de ces deux premières méthodes sont très similaires. Pour nous en convaincre, nous avons comparé la partition issue de la CAH avec celle des K-Means à l'aide de l'Indice de Rand Ajusté (ARI). L'ARI obtenu est de 0.723. Cette valeur indique une

concordance assez bonne entre les deux classifications : les méthodes identifient des structures sous-jacentes cohérentes. Nous retenons la partition K-Means pour la suite de l’analyse car elle optimise directement l’inertie intra-classe.

L’analyse des profils moyens par classe, illustrée en Figure 3, permet de donner une interprétation aux trois groupes identifiés. La Figure 3 superpose la projection des individus sur le premier plan factoriel de l’ACP et les distributions des variables les plus discriminantes.

Les trois clusters se distinguent nettement selon deux axes : la morphologie et l’intensité de l’entraînement. Le cluster 1 (“Gabarits Imposants”) regroupe les individus de forte corpulence (poids et BMI élevés) s’entraînant à une intensité standard. À l’opposé, le cluster 2 (“Athlètes d’Endurance”) se distingue par une performance physique maximale (durée, calories) associée à une morphologie sèche. Enfin, le cluster 3 (“Fitness / Loisir”) rassemble des gabarits plus légers engagés dans une pratique d’entretien modérée.




FIGURE 3 : Caractérisation des clusters retenus ($K=3$). Gauche : Projection sur le plan factoriel. Droite : Boxplots des variables discriminantes.

Mélanges gaussiens

Une dernière approche exploratoire repose sur les Mélanges Gaussiens. Afin de challenger et d’affiner la partition en 3 classes précédemment identifiée, nous avons testé un nombre de composantes G variant de 2 à 10. Cette plage de recherche permet de détecter d’éventuelles sous-structures fines tout en excluant les modèles trop fragmentés ($G > 10$). Bien que théoriquement optionnel pour les Mélanges Gaussiens, nous avons conservé les données centrées-réduites. Ce choix méthodologique assure une comparabilité stricte avec les K-Means en neutralisant les effets d’unités, garantissant ainsi que les différences observées soient purement algorithmiques.




FIGURE 4 : Sélection du modèle GMM. Gauche : Top 3 des modèles selon le critère ICL. Droite : Évolution du critère BIC selon le nombre de clusters.

Comme illustré en Figure 4, les deux critères convergent vers le modèle VEV (volumes variables, formes égales, orientations variables) avec un nombre de composantes $K = 7$. Ce passage de 3 à 7 classes suggère que les groupes identifiés précédemment par les K-Means sont en réalité des “méta-classes” composées de sous-populations distinctes.

L’analyse des probabilités d’appartenance (Figure 6) confirme la robustesse de la segmentation. Pour les clusters 1, 5 et 7, la probabilité maximale frôle 1, indiquant des profils très typés. À l’inverse, les clusters centraux (2, 3, 4) présentent une dispersion plus forte, traduisant une frontière plus floue entre ces profils de pratiquants “moyens”.

Comparaison

L’analyse croisée des distributions et de la matrice de confusion révèle que les 7 classes issues des mélanges constituent une subdivision logique des 3 profils K-Means comme on peut le voir sur la matrice de confusion (Figure 7).

Le groupe des “Gabarits Imposants” est ainsi scindé en deux profils morphologiques distincts : les “Lourds/Puissants” (Cluster 5) et les “Grands” (Cluster 6), discriminant clairement la masse de la taille. De même, les “Athlètes d’Endurance” se nuancent par intensité entre “Ultra-Endurance” (Cluster 1) et “Endurance Haute” (Cluster 7), tandis que le groupe hétérogène “Fitness/Loisir” éclate en trois sous-populations (2, 3, 4) capturant des variations métaboliques subtiles.

Cette inclusion quasi-exclusive des nouvelles classes dans les anciennes confirme la forte




FIGURE 5 : Caractérisation des clusters retenus ($G=7$). Gauche : Projection sur le plan factoriel. Droite : Boxplots des variables discriminantes.




FIGURE 6 : Robustesse de la classification. Distribution des probabilités maximales d'appartenance par cluster (Incertitude).




FIGURE 7 : Analyse croisée des partitions. Gauche : Matrice de confusion. Droite : Plan factoriel MCA.

cohérence structurelle entre les deux méthodes. Les deux approches ne s’opposent pas mais offrent deux niveaux de lecture complémentaires. La matrice de confusion démontre une excellente compatibilité entre les deux modèles. La partition en 7 classes (Mélanges) agit comme une sous-segmentation logique de la partition en 3 classes (K-Means). Le modèle K-Means/CAH ($K = 3$) offre une lecture synthétique et opérationnelle (“Gabarits”, “Endurants”, “Fitness”). Il est robuste (validé par Silhouette et Calinski-Harabasz) et facile à interpréter. Le modèle de Mélanges ($K = 7$) apporte une finesse supérieure. Il permet notamment de distinguer la “taille” de la “masse” (ex : distinction entre les clusters 5 et 6) et de nuancer les niveaux d’intensité. L’analyse MCA (Figure 7) confirme cette interprétation : la proximité factorielle entre les classes obtenue à partir des Kmeans K et celles obtenue par méthodes de mélanges G prouve mathématiquement que le modèle de mélange n’est qu’une subdivision des classes K-Means.

Conclusion

Dans une optique de pilotage général et de clarté, nous recommandons de retenir la partition K-Means en 3 classes. Bien que le modèle de mélange soit statistiquement optimal (critère BIC), la division en 7 groupes complexifie l’interprétation sans nécessairement apporter de levier d’action proportionnel pour une segmentation généraliste. La partition en 3 classes capture l’essentiel de la variance (morphologie et intensité) et permet de définir des profils types suffisamment distincts. Le modèle à 7 classes pourra être conservé en tant qu’outil de “second niveau” si un besoin de personnalisation très fine se fait sentir ultérieurement.