

Analyse du nombre de calories brûlées

Ilias Bouhalla, Chaima Sghir, Brice Vergnou

Introduction

Ce projet a pour objectif d'analyser les facteurs influençant la dépense énergétique lors de séances sportives à partir d'un jeu de données décrivant les caractéristiques physiques, physiologiques et les pratiques d'adhérents d'une salle de sport. Après une analyse descriptive et exploratoire du jeu de données, nous mobilisons des tests d'hypothèses, des méthodes de clustering et différentes approches de modélisation statistique afin d'étudier le nombre de calories brûlées et le niveau d'expérience des pratiquants. Une attention particulière est portée à la sélection de variables, à l'interprétation des modèles et à l'analyse des résidus, dans une logique d'aller-retour entre exploration et modélisation.

Analyse descriptive

TABLE 1 : Aperçu des premières lignes du jeu de données

age	gender	weight	height	bpm_ave	duration	calories	type	fat	water	freq	level	bmi
56	Male	88.3	1.71	157	1.69	1313	Yoga	12.6	3.5	4	3	30.20
46	Fe- male	74.9	1.53	151	1.30	883	HIIT	33.9	2.1	4	2	32.00
32	Fe- male	68.1	1.66	122	1.11	677	Cardio	33.4	2.3	4	2	24.71
25	Male	53.2	1.70	164	0.59	532	Strength	28.8	2.1	3	1	18.41
38	Male	46.1	1.79	158	0.64	556	Strength	29.2	2.8	3	1	14.39
56	Fe- male	58.0	1.68	156	1.59	1116	HIIT	15.5	2.7	5	3	20.55
36	Male	70.3	1.72	169	1.49	1385	Cardio	21.3	2.3	3	2	23.76
40	Fe- male	69.7	1.51	141	1.27	895	Cardio	30.6	1.9	3	2	30.57
28	Male	121.7	1.94	127	1.03	719	Strength	28.9	2.6	4	2	32.34
28	Male	101.8	1.84	136	1.08	808	Cardio	29.7	2.7	3	1	30.07

Variables qualitatives

Nous identifions quatre variables qualitatives : **type**, **level**, **gender**, **freq**. Même si certaines d'entre elles (**level**, **freq**) sont données comme numériques, nous préférons les traiter comme variable qualitative car elles représentent des niveaux hiérarchiques distincts plutôt que des mesures continues.

(£) CHOSIRE ENTRE LES DEUX :

Une première interrogation porte sur l'influence potentielle du genre sur le choix de l'activité. La Figure 1 illustre la répartition des types d'exercices selon le sexe. Nous pouvons observer une répartition homogène, sans disparité apparente.

La Figure 1 illustre la distribution des types d'exercices en fonction du genre. Nous observons une répartition homogène des pratiques, sans disparité apparente entre hommes et femmes




FIGURE 1 : Répartition du type d'exercice selon le genre (proportions en colonne).

Variables quantitatives

Distribution de l'âge, du BMI et des calories brûlées

La Figure 2 illustre la distribution de trois variables importantes :

- l'âge des participants,
- leur indice de masse corporelle (BMI),
- ainsi qu'un boxplot des calories brûlées.

(£) CHOISIR ENTRE LES DEUX :

Nous observons sur la Figure 2 une différence d'échelle entre nos variables (ex : calories prend de très grande valeur comparé à la taille). Afin de traiter ces données avec des méthodes de type ACP (Analyse en composante principales), nous devrons plus tard normaliser nos données.

On voit que pour pouvoir manipuler ces données avec des méthodes comme l'ACP nous devrons plus tard normaliser nos données car celles-ci ne sont pas à la même échelle et ne suivent pas toutes une loi normale.




FIGURE 2 : Histogrammes de l'âge et du BMI, et boxplot des calories brûlées.

Calories selon le type et le niveau

La Figure 3 permet de visualiser l'influence du type d'exercice et du niveau.

(£) CHOSIRE ENTRE :

L'examen des distributions (Figure 3) met en évidence une hétérogénéité marquée de la dépense calorique selon le profil de la séance. Les exercices à haute intensité et les niveaux élevés sont associés à des valeurs médianes nettement supérieures. Néanmoins, la forte dispersion intra-classe témoigne d'une variabilité individuelle importante qui ne peut être résumée par ces seules catégories. Par ailleurs, une tendance haussière se dessine avec la fréquence d'entraînement. Ces constats légitiment l'inclusion de ces variables qualitatives (`type`, `freq`, `level`) comme facteurs explicatifs dans la modélisation ultérieure.

Les distributions montrent que les calories brûlées varient fortement selon le type d'exercice et le niveau : les pratiquants de niveau élevé ainsi que certains types d'entraînement plus intenses présentent des valeurs médianes plus hautes. La dispersion importante à l'intérieur de chaque groupe suggère toutefois une forte variabilité individuelle. La fréquence d'entraînement apparaît également liée à un accroissement global des calories. Ces observations indiquent que les facteurs qualitatifs influencent bien la dépense énergétique, ce qui justifie de les intégrer dans les modèles explicatifs.




FIGURE 3 : Calories brûlées selon le type d'exercice (à gauche) et le niveau (à droite).

Corrélations et relations bivariées

Enfin, la Figure 4 affiche les corrélations entre 2 paramètres.

La matrice de corrélation révèle des relations attendues : une forte association entre poids, BMI et masse grasse, et une corrélation positive marquée entre durée d'exercice, fréquence cardiaque et calories brûlées. Ces liens suggèrent que plusieurs variables décrivent des informations redondantes, ce qui justifie une réduction dimensionnelle (ACP) ou une sélection de variables dans les modèles. On observe aussi des variables quasi indépendantes, (£ bizarre la suite de la phrase) : utiles pour compléter l'explication du phénomène sans colinéarité excessive.

(£) BILAN ? On garde quoi en quanti, quoi en quali ? - Expliciter les variables (les citer)




FIGURE 4 : Matrice de corrélation des variables quantitatives.

Visualisation dans un espace à faible dimension

Variables quantitatives

Afin d'explorer la structure globale du jeu de données et d'identifier d'éventuels profils types parmi les individus, nous réalisons une Analyse en Composantes Principales (ACP) sur nos variables quantitatives. Cette méthode nous permet de réduire la dimensionnalité des variables quantitatives tout en conservant le maximum d'information.

age	gender	weight	height	bpm_ave
Min. :18.00	Female:462	Min. : 40.00	Min. :1.500	Min. :120.0
1st Qu.:28.00	Male :511	1st Qu.: 58.10	1st Qu.:1.620	1st Qu.:131.0
Median :40.00		Median : 70.00	Median :1.710	Median :143.0
Mean :38.68		Mean : 73.85	Mean :1.723	Mean :143.8
3rd Qu.:49.00		3rd Qu.: 86.00	3rd Qu.:1.800	3rd Qu.:156.0
Max. :59.00		Max. :129.90	Max. :2.000	Max. :169.0
duration	calories	type	fat	
Min. :0.500	Min. : 303.0	Cardio :255	Min. :10.00	
1st Qu.:1.040	1st Qu.: 720.0	HIIT :221	1st Qu.:21.30	
Median :1.260	Median : 893.0	Strength:258	Median :26.20	
Mean :1.256	Mean : 905.4	Yoga :239	Mean :24.98	
3rd Qu.:1.460	3rd Qu.:1076.0		3rd Qu.:29.30	
Max. :2.000	Max. :1783.0		Max. :35.00	
water	freq	level	bmi	
Min. :1.500	2:197	Min. :1.00	Min. :12.32	
1st Qu.:2.200	3:368	1st Qu.:1.00	1st Qu.:20.11	
Median :2.600	4:306	Median :2.00	Median :24.16	
Mean :2.627	5:102	Mean :1.81	Mean :24.91	
3rd Qu.:3.100		3rd Qu.:2.00	3rd Qu.:28.56	
Max. :3.700		Max. :3.00	Max. :49.84	

(£) CHOISIRE ENTRE :

Pendant notre analyse descriptive des données, nous avons remarquer la différence d'échelle entre nos différents variables quantitatives (ex : la variable calories varie entre 303 et 1783, tandis que les autres variables quantitatives présentent des valeurs beaucoup plus faibles). Il est donc essentiel de normaliser les données. Sans normalisation, la variable calories prendrait une importance disproportionnée et

influencerait fortement l'analyse, ce qui biaiserait les résultats et empêcherait une interprétation équilibrée des données

En affichant @summary_table , on remarque qu'il est essentiel de normaliser les données, car les variables n'ont pas la même échelle. Par exemple, la variable calories varie entre 303 et 1783, tandis que les autres variables quantitatives présentent des valeurs beaucoup plus faibles. Sans normalisation, la variable calories prendrait une importance disproportionnée et influencerait fortement l'analyse, ce qui biaiserait les résultats et empêcherait une interprétation équilibrée des données

Choix du nombre de dimensions (Éboulis des valeurs propres) : La première étape de l'ACP consiste à déterminer combien d'axes factoriels sont nécessaires pour résumer l'information. Nous analysons l'éboulis des valeurs propres pour identifier le nombre de dimensions qui capturent la majorité de l'inertie (variance) du nuage de données, tout en éliminant le "bruit" statistique. (£) ça fait très Gemini, éboulis ??




FIGURE 5 : Éboulis des valeurs propres : choix du nombre de dimensions

(£) **CHOISIR ENTRE :**

Les résultats de l'ACP (@summary_table1), montre une explication de 89.19 % de la variabilité totale des données avec 5 dimensions. Nous considérons alors qu'elles suffisent à représenter l'essentiel de l'information contenue dans nos variables.

On constate d'après @summary_table1 qu'il est possible de conserver uniquement les cinq premières dimensions, car à elles seules, elles expliquent 89.19 % de la variabilité totale des données. Cela signifie qu'elles suffisent à représenter l'essentiel de l'information contenue dans le jeu de données

Qualité de représentation des variables : Une fois les axes retenus, nous devons comprendre leur signification. Pour cela, nous examinons la qualité de représentation (Cos^2) des variables initiales sur chaque dimension. Une variable fortement représentée sur un axe contribue majoritairement à sa définition

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
age	0.005313815	0.001795596	0.01490023	6.195038e-01	0.336780057
weight	0.251556967	0.689499002	0.01241884	2.948873e-05	0.006017980
height	0.120009095	0.049006519	0.56178356	9.346186e-03	0.152948252
bpm_ave	0.024021638	0.025943921	0.15663385	3.808526e-01	0.392588829
duration	0.540535963	0.273427856	0.03084551	1.375423e-02	0.051162737
calories	0.670776262	0.209442703	0.06366851	3.295676e-05	0.012768095
fat	0.672092520	0.020931562	0.02477670	9.213223e-04	0.032153787
water	0.519724247	0.042137081	0.12784585	7.886467e-03	0.003807484
bmi	0.122087795	0.574242928	0.27897110	2.437898e-03	0.019316099

L'analyse de la **qualité de représentation des variables** (basée sur le critère du $\cos^2$) sur les cinq dimensions retenues @summary_table3 met en évidence la structure suivante :

- La **1ère dimension** est principalement caractérisée par les variables **fat**, **calories**, **duration** et **water**, qui y sont le mieux représentées.
- La **2ème dimension** est dominée par les variables de corpulence (**weight** et **bmi**).
- La **3ème dimension** est essentiellement structurée par la variable **height**.
- Enfin, alors que la **4ème dimension** ne semble capturer aucune contribution significative de la part des variables, l'âge (**age**) et la **fréquence cardiaque moyenne** (**bpm_ave**) sont les variables les plus corrélées à la **5ème dimension**.

(£) C'était très gémiesque ça mdr

Structure globale de la population (Nuage des individus) : Nous projetons les individus dans le nouvel espace réduit défini par les deux (£ C'est pas plutôt les deux axes principaux plutôt ?) premières composantes principales. Cette vue d'ensemble permet de repérer la topologie générale des données




FIGURE 6 : Projection des individus sur le premier plan factoriel (Dim 1 et 2)

Le graphique n'est pas très lisible et ne permet pas d'interpréter de nombreux éléments en détail. On observe néanmoins la formation de quelques groupes, même si les caractéristiques précises expliquant ces regroupements restent difficiles à identifier.

En colorant les individus selon le genre, le type ou la fréquence, certaines tendances apparaissent.




FIGURE 7 : Analyse des individus selon le Genre et la Fréquence et le type

Concernant le genre, une distinction est visible principalement sur l'axe 2 : les hommes se situent davantage du côté associé à des valeurs plus élevées de poids, taille et IMC, contrairement aux femmes.

En revanche, aucune tendance claire ne se dégage concernant le type, les individus étant répartis de manière trop homogène.

Pour la fréquence, on observe qu'elle influence surtout l'axe 1 : plus on se déplace vers la droite, plus la fréquence augmente. Cela est cohérent avec le cercle de corrélation, où l'axe 1 est associé à un nombre plus élevé de calories brûlées et à une pratique plus régulière, ce qui reflète logiquement une fréquence d'entraînement plus importante.

Visualisation des relations entre variables (Cercle des corrélations) : Le cercle des corrélations projette les vecteurs des variables quantitatives sur le premier plan factoriel.




FIGURE 8 : Projection des variables sur le cercle des corrélations

(£) CHOISIR ENTRE :

L'examen du cercle des corrélations (£ METTRE LA FIGURE) révèle que la variable *fat* d'une part, et les variables *calories*, *duration*, etc. d'autre part, participent fortement à la construction de la première dimension. Leur projection dans des directions opposées illustre la corrélation négative existant entre ces indicateurs.

Dans le cercle de corrélation, on observe que les variables *fat* d'une part, et *calories*, *duration*, etc. d'autre part, contribuent toutes à la formation de la première dimension, mais dans des directions opposées, ce qui est cohérent avec leur relation inverse.

Par ailleurs, les variables *weight* (poids), *water* (consommation d'eau) et *height* (taille) influencent principalement la construction du deuxième axe factoriel.

Variables qualitatives

Afin de légitimer la projection des individus dans un espace factoriel réduit, il convient préalablement de vérifier l'existence de liaisons statistiques entre les variables qualitatives. Nous avons pour cela réalisé des tests du Chi-deux d'indépendance de Pearson dont les p-valeurs sont reportées dans la Table 2.

TABLE 2 : Test du CHi2 de Pearson croisés

	gender	type	freq	level
gender	0.00000	0.70523	0.71553	0.99360
type	0.70523	0.00000	0.76385	0.44708
freq	0.71553	0.76385	0.00000	0.00000
level	0.99360	0.44708	0.00000	0.00000

Au seuil de signification $\alpha = 5\%$, l'hypothèse d'indépendance ne peut être rejetée pour les croisements impliquant la variable Genre (croisée avec Type, Fréquence et Niveau), ainsi que pour le couple Type-Fréquence. Ces résultats confirment les statistiques descriptives : le genre n'est pas un facteur discriminant et n'influence ni la pratique ni la performance. En revanche, une dépendance significative est mise en évidence entre le Niveau et la Fréquence (rejet de l'hypothèse d'indépendance), validant la pertinence d'une analyse factorielle ciblée sur ces deux variables.




FIGURE 9 : Projection des différentes modalités Level et Freq sur le premier plan factorielle

L'analyse dimensionnelle (voir Figure 9) révèle une structure expliquant la totalité de l'information (100 %), dominée à 68 % par un premier axe traduisant l'intensité de la pratique. Cet axe horizontal ordonne les individus selon une progression linéaire, opposant les valeurs faibles à gauche aux valeurs fortes à droite, tandis que le second axe (32 %) discrimine les profils selon leur degré de modération (opposition extrême/moyen). L'étude des proximités confirme une corrélation directe et quasi parfaite : les débutants (Niveau 1) sont fortement associés aux fréquences faibles (2), alors que les niveaux experts (3) se regroupent avec les fréquences d'entraînement les plus élevées (5). Mathématiquement, ces résultats démontrent que la fréquence d'entraînement est le déterminant principal du niveau.

Une Analyse des Correspondances Multiples a été réalisée sur l'ensemble des quatre variables qualitatives afin d'identifier la structure globale des données. La projection des différentes modalités sur le premier plan factorielle (Figure 10) met en évidence une forte hiérarchie dans les contributions : les variables de niveau et de fréquence, projetées loin de l'origine, captent la majeure partie de l'inertie et structurent exclusivement les axes factoriels.

À l'inverse, les modalités liées au genre et au type de sport se concentrent autour du centre de gravité du nuage. Cette proximité avec l'origine indique une contribution marginale à la dispersion globale. Cette configuration confirme visuellement les résultats des tests statistiques précédents : la différenciation des individus ne repose pas leur genre ou leurs préférences d'activité, mais est structurée quasi-exclusivement par leur dynamique d'entraînement (couple Fréquence-Niveau).




FIGURE 10 : Projection des différentes modalités sur le premier plan factorielle

Test d'hypothèses

Test d'adéquation du nombre de calories brulées à la loi normale

(£) CHOISIR ENTRE :

Avant de procéder à la comparaison des moyennes de dépense énergétique, nous examinons l'hypothèse de normalité de la variable calories. Cette étape est déterminante pour orienter le choix entre des méthodes paramétriques (fondées sur la moyenne) et des méthodes robustes fondées sur les rangs (test non paramétriques).

Vérification de la normalité de la variable cible : Avant d'effectuer des tests de comparaison de moyennes sur la variable calories, nous devons vérifier si celle-ci suit une distribution normale

Lilliefors (Kolmogorov-Smirnov) normality test

```
data: gym$calories
D = 0.028321, p-value = 0.0633
```

(£) CHOISIR ENTRE :

Nous avons d'abord effectué un test de Kolmogorov-Smirnov (correction de Lilliefors). Celui-ci renvoie une p-valeur de 0,0633. Bien que l'hypothèse nulle (H_0) de normalité ne soit pas rejetée au seuil $\alpha = 5\%$, ce résultat s'avère fragile au seuil $\alpha = 10\%$. Pour lever l'ambiguïté, nous avons procédé au test de Shapiro-Wilk, plus puissant pour détecter les écarts à la normalité.

On a commencé par faire un test de normalité de Kolmogorov-Smirnov (de Lilliefors) là on trouve une p-valeur de 0.0633 ce qui est limite en effet on rejettera si on prend un test à niveau 5% on acceptera l'hypothèse hors pour un test à niveau 10% on rejettera l'hypothèse donc on a décidé de refaire un autre test de Shapiro-Wilk

Shapiro-Wilk normality test

```
data: gym$calories
W = 0.99176, p-value = 2.982e-05
```

(£) CHOISIR ENTRE :

La p-valeur obtenue ($p = 2,982 \times 10^{-5}$) étant largement inférieure au seuil de 5%, nous rejetons l'hypothèse nulle. La variable calories ne suit pas une loi normale, ce qui impose l'utilisation de tests non paramétriques pour la suite de l'étude.

Avec le test de Shapiro-Wilk on trouve une p-valeur de 2.982e-0.5 qui est très faible donc en conclusion on a rejeté l'hypothèse

La variable calories brûlées ne suit pas une loi normale

(£) CHOISIR ENTRE :

La condition de normalité n'étant pas respectée, nous appliquons le test de Wilcoxon-Mann-Whitney (test non paramétrique de comparaison des rangs) pour tester l'influence du genre sur la dépense énergétique. H_0 : Les distributions de calories sont identiques pour les deux sexes. H_1 : Il existe un décalage significatif entre les distributions.

Test d'hypothèse : Influence du genre sur les calories : La normalité n'étant pas vérifiée, nous utilisons le test non paramétrique de Wilcoxon-Mann-Whitney pour déterminer si la distribution des calories brûlées diffère significativement entre les hommes et les femmes

Dépendance entre variables

Wilcoxon rank sum test with continuity correction

```
data: calories by gender
W = 98828, p-value = 1.139e-05
alternative hypothesis: true location shift is not equal to 0
```

(£) CHOISIR ENTRE :

La p-valeur obtenue ($p = 1,139 \times 10^{-5}$) nous conduit à rejeter l'hypothèse d'égalité des distributions. Il existe une différence statistiquement significative de calories brûlées entre les hommes et les femmes. Toutefois, nous avons affiné cette analyse en stratifiant les tests par type d'activité (type). Les résultats révèlent une nuance majeure. Pour les activités HIIT, Cardio et Strength, l'effet du genre est significatif ($p < 0,05$). Le métabolisme et le gabarit moyen, généralement plus élevés chez les hommes, expliquent cette différence. Pour le Yoga, la p-valeur ($p = 0,3946$) ne permet pas de rejeter H_0 . Nous en concluons que l'impact du genre sur la dépense calorique est conditionné par la nature de l'effort fourni.

La p-valeur obtenue est 1.139e-05 qui est très faible donc on rejette donc l'hypothèse nulle : il y a une différence significative de calories brûlées entre les hommes et les femmes.

Afin d'affiner l'analyse, nous avons appliqué le test de Wilcoxon-Mann-Whitney séparément pour chaque type de sport. Les résultats mettent en évidence une nuance importante : Résultats pour Type= Yoga

Wilcoxon rank sum test with continuity correction

```
data: calories by gender
W = 6596.5, p-value = 0.3946
alternative hypothesis: true location shift is not equal to 0
```

Résultats pour Type= HIIT

Wilcoxon rank sum test with continuity correction

```
data: calories by gender
W = 4893, p-value = 0.01116
alternative hypothesis: true location shift is not equal to 0
```

Résultats pour Type= Cardio

Wilcoxon rank sum test with continuity correction

```
data:  calories by gender
W = 6319.5, p-value = 0.00215
alternative hypothesis: true location shift is not equal to 0
```

Résultats pour Type= Strength

Wilcoxon rank sum test with continuity correction

```
data:  calories by gender
W = 6850, p-value = 0.01529
alternative hypothesis: true location shift is not equal to 0
```

(£)

Nous cherchons à déterminer si le comportement des adhérents (choix du sport et niveau d'expérience) est lié au genre.

Pour le HIIT, le Cardio et le Strength, la p-valeur est inférieure au seuil de 5% . On rejette donc l'hypothèse nulle : pour ces activités intenses, le genre a un impact significatif sur la dépense calorique (les hommes brûlant généralement plus de calories que les femmes du fait de leur métabolisme et gabarit moyen supérieur). En revanche, pour le Yoga, la p-valeur est élevée 0.3946 . On ne peut donc pas rejeter l'hypothèse nulle. Cela suggère que pour cette pratique spécifique, la dépense calorique ne diffère pas significativement entre les hommes et les femmes dans notre échantillon.

Cela montre que la conclusion générale ("le genre influence les calories") n'est pas absolue : elle dépend du type d'activité.

Nous cherchons désormais à savoir si le comportement des individus (choix du sport, niveau d'expérience) est conditionné par leur genre. Étant donné qu'il s'agit du croisement de deux variables qualitatives, nous appliquons des tests du (Khi-2) d'indépendance

Pearson's Chi-squared test

```
data:  tab_type_gender
X-squared = 1.4013, df = 3, p-value = 0.7052
```

- Concernant le lien **Type de sport / Genre**, la p-valeur obtenue est très élevée (**p = 0.7052**). Nous ne rejetons donc pas l'hypothèse nulle d'indépendance. Le choix de la discipline sportive ne dépend pas significativement du genre dans notre échantillon

Pearson's Chi-squared test

```
data:  tab6
X-squared = 0.012838, df = 2, p-value = 0.9936
```

- De même pour le lien **Niveau / Genre**, la p-valeur est proche de 1 (**p = 0.9936**), ce qui confirme une absence totale de dépendance. La répartition des niveaux d'expérience (débutant, intermédiaire, expert) est statistiquement identique chez les hommes et les femmes.

Clustering des individus

Cette section vise à regrouper les individus de l'étude en groupes homogènes (clusters). L'analyse repose sur les variables quantitatives de notre jeu de données. Les variables qualitatives (`gender`, `type`, `level`, `freq`) ont été écartées de la construction des classes.

Pour garantir une segmentation robuste, nous avons exploré plusieurs algorithmes de classification sur les données préalablement centrées et réduites. Cette normalisation est cruciale pour que les variables à forte variance (comme les calories) ne dominent pas le calcul des distances par rapport aux variables à faible amplitude (comme la taille).

Classification Ascendante Hiérarchique (CAH) : Utilisée en première approche avec la distance euclidienne et le critère de Ward. Ce critère minimise la perte d'inertie inter-classe à chaque étape de regroupement, favorisant des classes compactes. Elle nous permet aussi de visualiser la structure des données via un dendrogramme.

K-Means : Cet algorithme itératif réalloue les individus pour minimiser l'inertie intra-classe totale.

Mélanges gaussiens : Approche probabiliste modélisant les données par une superposition de lois normales. Elle permet de s'adapter à des formes et volumes de classes variés (via la covariance) et d'estimer une probabilité d'appartenance pour chaque individu.

K-means

Une première approche naturelle pourrait être d'essayer de minimiser l'inertie intra-classe en utilisant un algorithme des K-means. Pour connaître le nombre de classes optimales, on utilise deux critères.

Courbe d'inertie : On observe une cassure ("coude") à $K = 3$ sur la Figure 11, indiquant que l'ajout d'un quatrième groupe n'apporte pas une baisse significative de l'inertie intra-classe.

Silhouette moyenne : Le score atteint son maximum global pour $K = 3$ sur la Figure 11, confirmant que les individus sont, en moyenne, bien mieux classés dans une structure à trois classes.




FIGURE 11 : Méthode du coude et Silhouette

Classification hiérarchique

Une seconde approche explorée est celle d'un modèle de classification emboîté (CAH). Cette méthode a été privilégiée pour sa capacité à révéler l'architecture structurelle des données sans imposer de nombre de classes a priori. Le choix du nombre de groupes K repose sur plusieurs critères : l'analyse du dendrogramme et le critère de Calinski-Harabasz.

La Figure 12 synthétise ces indicateurs. Le dendrogramme met en évidence une perte d'inertie très significative lors du passage de 3 à 2 classes, suggérant que la partition en 3 groupes est la plus naturelle. Cette observation est corroborée par l'indicateur de Calinski-Harabasz, on observe un maximum du critère à 3 classes.




FIGURE 12 : Critères de sélection du nombre de classes. Gauche : Dendrogramme de la CAH. Droite : Méthode de Calinski-Harabasz.

On remarque la classification issues de ces deux premières méthodes sont très similaires. Pour nous en convaincre, nous avons comparé la partition issue de la CAH avec celle des K-Means à l'aide de l'Indice de Rand Ajusté (ARI). L'ARI obtenu est de 0.723. Cette valeur indique une concordance assez bonne entre les deux classifications : les méthodes identifient des structures sous-jacentes cohérentes. Nous retenons la partition K-Means pour la suite de l'analyse car elle optimise directement l'inertie intra-classe.

L'analyse des profils moyens par classe, illustrée en Figure 13, permet de donner une interprétation aux trois groupes identifiés. La Figure 13 superpose la projection des individus sur le premier plan factoriel de l'ACP et les distributions des variables les plus discriminantes.

Les trois clusters se distinguent nettement selon deux axes : la morphologie et l'intensité de l'entraînement. Le cluster 1 ("Gabarits Imposants") regroupe les individus de forte corpulence (poids et BMI élevés) s'entraînant à une intensité standard. À l'opposé, le cluster 2 ("Athlètes d'Endurance") se distingue par une performance physique maximale (durée, calories) associée à une morphologie sèche. Enfin, le cluster 3 ("Fitness / Loisir") rassemble des gabarits plus légers engagés dans une pratique d'entretien modérée.

Mélanges gaussiens

Une dernière approche exploratoire repose sur les Mélanges Gaussiens. Afin de challenger et d'affiner la partition en 3 classes précédemment identifiée, nous avons testé un nombre de composantes G variant de 2 à 10. Cette plage de recherche permet de détecter d'éventuelles sous-structures fines tout en excluant les modèles trop fragmentés ($G > 10$). Bien que théoriquement optionnel pour les Mélanges Gaussiens, nous avons conservé les données centrées-réduites. Ce choix méthodologique assure une comparabilité stricte avec les K-Means en neutralisant les effets d'unités, garantissant ainsi que les différences observées soient purement algorithmiques.

Comme illustré en Figure 14, les deux critères convergent vers le modèle VEV (volumes variables, formes égales, orientations variables) avec un nombre de composantes $K = 7$. Ce passage de 3 à 7 classes suggère que les groupes identifiés précédemment par les K-Means sont en réalité des "méta-classes" composées de sous-populations distinctes.

L'analyse des probabilités d'appartenance (Figure 16) confirme la robustesse de la segmentation. Pour les clusters 1, 5 et 7, la probabilité maximale frôle 1, indiquant des profils très typés. À l'inverse, les clusters centraux (2, 3, 4) présentent une dispersion plus forte, traduisant une frontière plus floue entre ces profils de pratiquants "moyens".




FIGURE 13 : Caractérisation des clusters retenus (K=3). Gauche : Projection sur le plan factoriel. Droite : Boxplots des variables discriminantes.




FIGURE 14 : Sélection du modèle GMM. Gauche : Top 3 des modèles selon le critère ICL. Droite : Évolution du critère BIC selon le nombre de clusters.




FIGURE 15 : Caractérisation des clusters retenus ($G=7$). Gauche : Projection sur le plan factoriel. Droite : Boxplots des variables discriminantes.




FIGURE 16 : Robustesse de la classification. Distribution des probabilités maximales d'appartenance par cluster.




FIGURE 17 : Analyse croisée des partitions. Gauche : Matrice de confusion. Droite : Plan factoriel MCA.

Comparaison

L'analyse croisée des distributions et de la matrice de confusion révèle que les 7 classes issues des mélanges constituent une subdivision logique des 3 profils K-Means comme on peut le voir sur la matrice de confusion (Figure 17).

Le groupe des “Gabarits Imposants” est ainsi scindé en deux profils morphologiques distincts : les “Lourds/Puissants” (Cluster 5) et les “Grands” (Cluster 6), discriminant clairement la masse de la taille. De même, les “Athlètes d'Endurance” se nuancent par intensité entre “Ultra-Endurance” (Cluster 1) et “Endurance Haute” (Cluster 7), tandis que le groupe hétérogène “Fitness/Loisir” éclate en trois sous-populations (2, 3, 4) capturant des variations métaboliques subtiles.

Cette inclusion quasi-exclusive des nouvelles classes dans les anciennes confirme la forte cohérence structurelle entre les deux méthodes. Les deux approches ne s'opposent pas mais offrent deux niveaux de lecture complémentaires. La matrice de confusion démontre une excellente compatibilité entre les deux modèles. La partition en 7 classes (Mélanges) agit comme une sous-segmentation logique de la partition en 3 classes (K-Means). Le modèle K-Means/CAH ($K = 3$) offre une lecture synthétique et opérationnelle (“Gabarits”, “Endurants”, “Fitness”). Il est robuste (validé par Silhouette et Calinski-Harabasz) et facile à interpréter. Le modèle de Mélanges ($K = 7$) apporte une finesse supérieure. Il permet notamment de distinguer la “taille” de la “masse” (ex : distinction entre les clusters 5 et 6) et de nuancer les niveaux d'intensité. L'analyse MCA (Figure 17) confirme cette interprétation : la proximité factorielle entre les classes obtenue à partir des Kmeans K et celles obtenue par méthodes de mélanges G prouve mathématiquement que le modèle de mélange n'est qu'une subdivision des classes K-Means.

Conclusion

Dans une optique de pilotage général et de clarté, nous recommandons de retenir la partition K-Means en 3 classes. Bien que le modèle de mélange soit statistiquement optimal (critère BIC), la division en 7 groupes complexifie l'interprétation sans nécessairement apporter de levier d'action proportionnel pour une segmentation généraliste. La partition en 3 classes capture l'essentiel de la variance (morphologie et intensité) et permet de définir des profils types suffisamment distincts. Le modèle à 7 classes pourra être conservé en tant qu'outil de “second niveau” si un besoin de personnalisation très fine se fait sentir ultérieurement.

Étude du nombre de calories brûlées

Cette partie vise à modéliser le nombre de calories brûlées au cours d'une séance d'entraînement en fonction des variables explicatives disponibles.

Modélisation à partir des variables quantitatives

Nous ajustons un modèle de **régression linéaire multiple** reliant le nombre de calories brûlées aux variables quantitatives du jeu de données.

$$\text{Calories}_i = \beta_0 + \beta_1 \text{age}_i + \beta_2 \text{weight}_i + \beta_3 \text{height}_i + \beta_4 \text{bpm_ave}_i + \beta_5 \text{duration}_i + \beta_6 \text{fat}_i + \beta_7 \text{water}_i + \beta_8 \text{freq}_i + \beta_9 \text{bmi}_i + \varepsilon_i$$

Dans la Figure 18, les résidus sont globalement centrés autour de zéro, ce qui valide l'hypothèse d'espérance nulle des erreurs. Le Q-Q plot indique une déviation modérée à la normalité dans les queues, et le graphique « Scale-Location » suggère une légère hétéroscédasticité, sans observation fortement influente. En ajoutant des interactions, nous observons sur la Figure 19 que cela permet d'améliorer la qualité des résidus, notamment en réduisant la courbure observée précédemment. Cependant, ce modèle devient très complexe, avec un grand nombre de paramètres, ce qui peut conduire à du sur-ajustement. Cela justifie l'utilisation d'une méthode de sélection de variables afin d'obtenir un modèle plus simple et plus interprétable.




FIGURE 18 : Résidus du modèle linéaire quantitatif




FIGURE 19 : Résidus du modèle linéaire quantitatif avec interactions

Effet des variables qualitatives : niveau et type de sport

Nous étudions l'effet du niveau d'expérience et du type de sport sur les calories brûlées à l'aide d'une **ANOVA** à deux facteurs avec interaction.

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}, \quad \begin{cases} i = 1, \dots, I \\ j = 1, \dots, J \\ k = 1, \dots, n_{ij} \end{cases}$$



FIGURE 20 : Calories brûlées selon le niveau d'expérience et le type de sport

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
level	2	36801094	18400547	504.827	<2e-16 ***
type	3	134164	44721	1.227	0.299
level:type	6	289090	48182	1.322	0.244
Residuals	961	35027713	36449		

Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'	0.1 ' ' 1

La Figure 20 montre une augmentation nette du nombre de calories brûlées avec le niveau d'expérience, quel que soit le type de sport pratiqué. L'ANOVA confirme un effet significatif du niveau ($p < 2 \times 10^{-16}$), tandis que l'effet du type de sport n'est pas significatif. De plus, l'interaction entre le niveau et le type de sport n'est pas significative, ce qui indique que l'influence du niveau sur les calories brûlées est similaire pour tous les types de sport.

Sélection de modèle à l'aide du critère BIC

Nous considérons un modèle complet incluant toutes les variables explicatives, correspondant à une **ANCOVA**.

La Figure 21 illustre la sélection des variables explicatives par le critère BIC, qui privilégie des modèles parcimonieux. On observe que seules certaines variables sont retenues de manière stable, tandis que d'autres sont fréquemment exclues, ce qui traduit leur faible contribution explicative ou une redondance avec d'autres variables. Le meilleur modèle est $Y_i = \theta_0 + \theta_1 x_{\text{age},i} + \theta_2 x_{\text{bpm_vae},i} + \theta_3 x_{\text{duration},i} + \beta 1_{\text{gender=male},i} + \varepsilon_i$.

Analysis of Variance Table

Model 1: calories ~ age + gender + bpm_ave + duration




FIGURE 21 : Sélection des variables explicatives par le critère BIC.

```
Model 2: calories ~ age + gender + weight + height + bpm_ave + duration +
  fat + water + freq + bmi + type + level
Res.Df    RSS Df Sum of Sq    F Pr(>F)
1     968 1522442
2     955 1495626 13     26816 1.3171 0.1962
```

Un test de sous modèle avec le modèle complet nous donne une p-valeur de 0.2, ce qui nous permet d'accepter le sous-modèle.

La Figure 22 montre que les résidus du modèle sélectionné par le BIC sont globalement centrés autour de zéro, ce qui indique une absence de biais. Cependant, une légère non-linéarité apparaît dans la relation entre les résidus et les valeurs ajustées, avec une dispersion plus marquée pour les valeurs ajustées extrêmes. Cette forme suggère la présence d'une hétéroscédasticité modérée sans remettre en cause la pertinence globale du modèle dans le cadre de cette étude.

Etude du niveau d'expérience

Nous cherchons désormais à modéliser les Y_i désignant si l'individu est de niveau 1 ou de niveau 2 ou 3 en fonction des autres variables. La variable que l'on cherche à expliquer étant binaire et iid, on utilise un modèle logistique. On a donc $Y_i \sim B(\pi_\theta(x_i))$ avec $\text{logit}(\pi) = \ln\left(\frac{\pi}{1-\pi}\right) = \langle X, \theta \rangle$.

Call:

```
glm(formula = levelBis ~ ., family = binomial(link = "logit"),
    data = gym)
```

Coefficients:

```
Estimate Std. Error z value Pr(>|z|)
(Intercept) -2.445e+01 1.141e+03 -0.021 0.983
```




FIGURE 22 : Résidus en fonction des valeurs ajustées pour le modèle sélectionné par BIC.

age	-5.769e-03	1.616e-02	-0.357	0.721
genderMale	4.887e-01	6.055e-01	0.807	0.420
weight	-7.215e-03	4.543e-02	-0.159	0.874
height	-1.079e-01	4.165e+00	-0.026	0.979
bpm_ave	-5.649e-03	2.587e-02	-0.218	0.827
duration	3.462e+00	3.167e+00	1.093	0.274
calories	1.723e-03	4.357e-03	0.396	0.692
typeHIIT	-8.890e-02	3.441e-01	-0.258	0.796
typeStrength	2.677e-02	3.336e-01	0.080	0.936
typeYoga	2.881e-01	3.500e-01	0.823	0.410
fat	-2.750e-04	4.130e-02	-0.007	0.995
water	-2.717e-01	2.960e-01	-0.918	0.359
freq3	2.058e+01	1.141e+03	0.018	0.986
freq4	4.046e+01	1.482e+03	0.027	0.978
freq5	3.852e+01	2.043e+03	0.019	0.985
bmi	2.632e-02	1.389e-01	0.190	0.850

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1298.23 on 972 degrees of freedom
 Residual deviance: 414.51 on 956 degrees of freedom
 AIC: 448.51

Number of Fisher Scoring iterations: 19

En analysant les p-valeurs, nous constatons qu'aucune des variables n'est significative, ce qui est étrange car l'analyse descriptive montre que beaucoup de variables sont liées entre elles. En regardant de plus près, nous remarquons que l'estimation et l'écart-type des fréquences est très important par rapport aux autres variables. Nous allons donc faire un modèle sans cette variable.

Call:

```
glm(formula = levelBis ~ ., family = binomial(link = "logit"),
    data = gym)
```

Coefficients:

```

              Estimate Std. Error z value Pr(>|z|)
(Intercept) -1.121e+01  5.654e+00 -1.982  0.04748 *
age          -1.447e-03  1.096e-02 -0.132  0.89500
genderMale   -3.275e-01  3.716e-01 -0.881  0.37808
weight       -6.062e-02  3.095e-02 -1.959  0.05015 .
height        4.883e+00  2.869e+00  1.702  0.08882 .
bpm_ave      -4.678e-03  1.700e-02 -0.275  0.78312
duration      4.697e+00  1.997e+00  2.352  0.01868 *
calories      4.696e-04  2.750e-03  0.171  0.86443
typeHIIT     -5.131e-02  2.360e-01 -0.217  0.82789
typeStrength  1.694e-01  2.252e-01  0.752  0.45191
typeYoga      3.656e-01  2.385e-01  1.533  0.12520
fat          -7.614e-02  2.363e-02 -3.222  0.00127 **
water        -1.828e-01  1.989e-01 -0.919  0.35784
bmi           1.987e-01  9.452e-02  2.102  0.03553 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

(Dispersion parameter for binomial family taken to be 1)

```

Null deviance: 1298.23 on 972 degrees of freedom
Residual deviance: 892.45 on 959 degrees of freedom
AIC: 920.45

```

Number of Fisher Scoring iterations: 6

Nous observons désormais des p-valeurs plus cohérentes. En effet, nous avons certaines variables qui sont explicatives et d'autres non. Pour faire le tri dans ces variables, nous allons procéder à une sélection de modèle par critère BIC.

Cette procédure nous donne le modèle $Y_i = \beta_0 + \beta_1 x_{\text{fat},i} + \beta_2 x_{\text{duration},i}$.

Analysis of Deviance Table

```

Model 1: levelBis ~ fat + duration
Model 2: levelBis ~ age + gender + weight + height + bpm_ave + duration +
          calories + type + fat + water + bmi
  Resid. Df Resid. Dev Df Deviance Pr(>Chi)
1       970       906.38
2       959       892.45 11   13.936   0.2365

```

En réalisant un test de sous-modèle entre le résultat du choix par BIC et le modèle complet privé de `level`, nous obtenons une p-valeur de 0.2365, ce qui nous permet d'accepter le sous-modèle.

Conclusion (proposition)

Cette étude statistique nous a permis de décrypter les dynamiques de performance et les profils de sportifs de notre jeu de données. La démarche, articulée entre analyse exploratoire et modélisation prédictive, aboutit à plusieurs conclusions majeures :

Une segmentation cohérente : L'approche par clustering (K-Means et Mélanges Gaussiens) a mis en évidence trois profils types structurants. Nous distinguons les individus selon un compromis entre leur morphologie (gabarits imposants vs athlétiques) et l'intensité de leur pratique (endurance vs loisir).

Les déterminants de la dépense énergétique : La modélisation des calories brûlées révèle que, si les variables physiologiques brutes (poids, âge) comptent, la durée de la séance et la fréquence cardiaque moyenne sont les prédicteurs les plus robustes. Par ailleurs, nous avons démontré que l'influence du genre sur les calories est conditionnée par le type




FIGURE 23 : Sélection exhaustive des variables explicatives par le critère BIC pour le modèle logistique.

d'activité : elle est significative pour les efforts intenses (HIIT, Cardio) mais s'estompe pour des pratiques comme le Yoga.

La fréquence comme pilier du niveau : Enfin, l'étude du niveau d'expertise souligne que l'assiduité (fréquence hebdomadaire) est le facteur le plus discriminant. Notre modèle logistique parcimonieux confirme que la masse grasse et la durée des séances suffisent à caractériser efficacement le passage d'un niveau débutant à un niveau confirmé.

En définitive, ce projet illustre l'intérêt des méthodes de réduction dimensionnelle et de sélection de modèles (critère BIC) pour transformer un jeu de données complexe en leviers de compréhension opérationnels.