

Projet_AD_EMS

Quarto

Quarto enables you to weave together content and executable code into a finished document. To learn more about Quarto see <https://quarto.org>.

Running Code

When you click the **Render** button a document will be generated that includes both content and the output of embedded code. You can embed code like this:

```
      age      gender      weight      height      bpm_ave
Min.   :18.00  Female:462  Min.    : 40.00  Min.    :1.500  Min.    :120.0
1st Qu.:28.00  Male   :511  1st Qu.: 58.10  1st Qu.:1.620  1st Qu.:131.0
Median :40.00                      Median : 70.00  Median :1.710  Median :143.0
Mean   :38.68                      Mean   : 73.85  Mean   :1.723  Mean   :143.8
3rd Qu.:49.00                      3rd Qu.: 86.00  3rd Qu.:1.800  3rd Qu.:156.0

      duration      calories      type      fat
Min.    :0.500  Min.      : 303.0  Cardio  :255  Min.    :10.00
1st Qu.:1.040  1st Qu.: 720.0  HIIT    :221  1st Qu.:21.30
Median :1.260  Median : 893.0  Strength:258  Median :26.20
Mean    :1.256  Mean    : 905.4  Yoga    :239  Mean    :24.98
3rd Qu.:1.460  3rd Qu.:1076.0                3rd Qu.:29.30

      water      freq      level      bmi
Min.    :1.500  2:197  Min.    :1.00  Min.    :12.32
1st Qu.:2.200  3:368  1st Qu.:1.00  1st Qu.:20.11
Median :2.600  4:306  Median :2.00  Median :24.16
Mean    :2.627  5:102  Mean    :1.81  Mean    :24.91
3rd Qu.:3.100      3rd Qu.:2.00  3rd Qu.:28.56
[ reached 'max' / getOption("max.print") -- omitted 1 row ]
```

Il est essentiel de normaliser les données, car les variables n'ont pas la même échelle. Par exemple, la variable *calories* varie entre 303 et 1783, tandis que les autres variables quantitatives présentent des valeurs beaucoup plus faibles. Sans normalisation, la variable *calories* prendrait une importance disproportionnée et influencerait fortement l'analyse, ce qui biaiserait les résultats et empêcherait une interprétation équilibrée des données

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	2.926118302	32.51242558	32.51243
comp 2	1.886427168	20.96030186	53.47273
comp 3	1.271844140	14.13160155	67.60433
comp 4	1.034764938	11.49738820	79.10172
comp 5	1.007543322	11.19492580	90.29664
comp 6	0.528664929	5.87405477	96.17070
comp 7	0.322988781	3.58876424	99.75946
comp 8	0.015430415	0.17144906	99.93091
comp 9	0.006218005	0.06908894	100.00000

[1] 9




Figure 1: FAIS LE

On constate qu'il est possible de conserver uniquement les quatre premières dimensions, car à elles seules, elles expliquent 79,10 % de la variabilité totale des données. Cela signifie qu'elles suffisent à représenter l'essentiel de l'information contenue dans le jeu de données

	Dim.1	Dim.2	Dim.3	Dim.4	Dim.5
age	0.005313815	0.001795596	0.01490023	6.195038e-01	0.336780057
weight	0.251556967	0.689499002	0.01241884	2.948873e-05	0.006017980
height	0.120009095	0.049006519	0.56178356	9.346186e-03	0.152948252
bpm_ave	0.024021638	0.025943921	0.15663385	3.808526e-01	0.392588829
duration	0.540535963	0.273427856	0.03084551	1.375423e-02	0.051162737
calories	0.670776262	0.209442703	0.06366851	3.295676e-05	0.012768095
fat	0.672092520	0.020931562	0.02477670	9.213223e-04	0.032153787
water	0.519724247	0.042137081	0.12784585	7.886467e-03	0.003807484
bmi	0.122087795	0.574242928	0.27897110	2.437898e-03	0.019316099

L'analyse de la **qualité de représentation des variables** (basée sur le critère du $\cos^2$) sur les cinq dimensions retenues met en évidence la structure suivante :

- La **1ère dimension** est principalement caractérisée par les variables *fat*, *calories*, *duration* et *water*, qui y sont le mieux représentées.
- La **2ème dimension** est dominée par les variables de corpulence (*weight* et *bmi*).
- La **3ème dimension** est essentiellement structurée par la variable *height*.
- Enfin, alors que la **4ème dimension** ne semble capturer aucune contribution significative de la part des variables, l'âge et la **fréquence cardiaque moyenne** (*bpm_ave*) sont les variables les plus corrélées à la **5ème dimension**.




Figure 2: FAIS LE 4

Le graphique n'est pas très lisible et ne permet pas d'interpréter de nombreux éléments en détail. On observe néanmoins la formation de quelques groupes, même si les caractéristiques précises expliquant ces regroupements restent difficiles à identifier.

En colorant les individus selon le genre, le type ou la fréquence, certaines tendances apparaissent.



(a) Projection selon le Genre (b) Projection selon la Fréquence (c) Projection selon le Type

Figure 3: Analyse des individus selon le Genre et la Fréquence

Concernant le genre, une distinction est visible principalement sur l'axe 2 : les hommes se situent davantage du côté associé à des valeurs plus élevées de poids, taille et IMC, contrairement aux femmes.

En revanche, aucune tendance claire ne se dégage concernant le type, les individus étant répartis de manière trop homogène.

Pour la fréquence, on observe qu'elle influence surtout l'axe 1 : plus on se déplace vers la droite, plus la fréquence augmente. Cela est cohérent avec le cercle de corrélation, où l'axe 1 est associé à un nombre plus élevé de calories brûlées et à une présence plus régulière en salle, ce qui reflète logiquement une fréquence d'entraînement plus importante.




Figure 4: FAIS LE 8

Dans le cercle de corrélation, on observe que les variables *fat* d'une part, et *calories*, *duration*, etc. d'autre part, contribuent toutes à la formation de la première dimension, mais dans des directions opposées, ce qui est cohérent avec leur relation inverse.

Par ailleurs, les variables *poids*, la *consommation d'eau* et *taille* influencent principalement la construction du deuxième axe factoriel

```
#| echo: false
#| warning: false

library(nortest)
lillie.test(gym$calories)
```

Lilliefors (Kolmogorov-Smirnov) normality test

```
data: gym$calories
D = 0.028321, p-value = 0.0633
```

On a commencé par faire un test de normalité de Kolmogorov-Smirnov (de Lilliefors) là on trouve une p-valeur de 0.0633 ce qui est limite en effet on rejettera si on prend un test à niveau

5% on acceptera l'hypothèse hors pour un test à niveau 10% on rejettera l'hypothèse donc on a décidé de refaire un autre test de Shapiro-Wilk

```
##| echo: false
##| warning: false

shapiro.test(gym$calories)
```

Shapiro-Wilk normality test

```
data:  gym$calories
W = 0.99176, p-value = 2.982e-05
```

Avec le test de Shapiro-Wilk on trouve une p-valeur de 2.982e-05 qui est très faible donc en conclusion on a rejeté l'hypothèse

La variable calories brûlées ne suit pas une loi normale

```
##| label: test_wilcoxon
##| echo: false
##| warning: false

# Test de Wilcoxon-Mann-Whitney
# H0 : Les distributions des calories sont identiques pour les hommes et les femmes
# H1 : Il y a un décalage significatif entre les deux distributions (une est plus grande que

res_wilcox <- wilcox.test(calories ~ gender, data = gym)
res_wilcox
```

Wilcoxon rank sum test with continuity correction

```
data:  calories by gender
W = 98828, p-value = 1.139e-05
alternative hypothesis: true location shift is not equal to 0
```

Comme les tests de normalité de Shapiro-Wilk ont rejeté l'hypothèse de normalité pour la variable calories.

Nous avons donc réalisé un test de Wilcoxon-Mann-Whitney (non-paramétrique). La p-valeur obtenue est 1.139e-05 qui est très faible donc on rejette donc l'hypothèse nulle : il y a une différence significative de calories brûlées entre les hommes et les femmes.

Wilcoxon rank sum test with continuity correction

```
data:  calories by gender
W = 6596.5, p-value = 0.3946
alternative hypothesis: true location shift is not equal to 0
```

Wilcoxon rank sum test with continuity correction

```
data:  calories by gender
W = 4893, p-value = 0.01116
alternative hypothesis: true location shift is not equal to 0
```

Wilcoxon rank sum test with continuity correction

```
data:  calories by gender
W = 6319.5, p-value = 0.00215
alternative hypothesis: true location shift is not equal to 0
```

Wilcoxon rank sum test with continuity correction

```
data:  calories by gender
W = 6850, p-value = 0.01529
alternative hypothesis: true location shift is not equal to 0
```

Afin d'affiner l'analyse, nous avons appliqué le test de Wilcoxon-Mann-Whitney séparément pour chaque type de sport. Les résultats mettent en évidence une nuance importante :

Pour le HIIT, le Cardio et le Strength, la p-valeur est inférieure au seuil de 5% . On rejette donc l'hypothèse nulle : pour ces activités intenses, le genre a un impact significatif sur la dépense calorique (les hommes brûlant généralement plus de calories que les femmes du fait de leur métabolisme et gabarit moyen supérieur). En revanche, pour le Yoga, la p-valeur est élevée 0.3946 . On ne peut donc pas rejeter l'hypothèse nulle. Cela suggère que pour cette pratique spécifique, la dépense calorique ne diffère pas significativement entre les hommes et les femmes dans notre échantillon.

Cela montre que la conclusion générale (“le genre influence les calories”) n’est pas absolue : elle dépend du type d’activité.

Pearson's Chi-squared test

```
data:  tab_type_gender
X-squared = 1.4013, df = 3, p-value = 0.7052
```

Pearson's Chi-squared test

```
data:  tab6
X-squared = 0.012838, df = 2, p-value = 0.9936
```

Nous avons réalisé des tests du Khi-deux d’indépendance pour vérifier si le genre influençait le choix du sport ou le niveau d’expérience.

- Concernant le lien **Type de sport / Genre**, la p-valeur obtenue est très élevée (**p = 0.7052**). Nous ne rejetons donc pas l’hypothèse nulle d’indépendance. Le choix de la discipline sportive ne dépend pas significativement du genre dans notre échantillon.
- De même pour le lien **Niveau / Genre**, la p-valeur est proche de 1 (**p = 0.9936**), ce qui confirme une absence totale de dépendance. La répartition des niveaux d’expérience (débutant, intermédiaire, expert) est statistiquement identique chez les hommes et les femmes.

On cherche à modéliser les Y_i désignant si l’individu est de niveau 1 ou de niveau 2 ou 3 en fonction des autres variables. La variable que l’on cherche à expliquer étant binaire et iid, on utilise un modèle logistique. On a donc $Y_i \sim B(\pi_\theta(x_i))$ avec $\text{logit}(\pi) = \ln(\frac{\pi}{1-\pi}) = \langle X, \theta \rangle$.

```
gym$levelBis <- ifelse(gym$level > 1, 1, 0)
gym$level <- NULL

gym$levelBis <- as.factor(gym$levelBis)

model_logit <- glm(levelBis ~ ., data = gym, family = binomial(link = "logit"))
summary(model_logit)
```


Call:

```
glm(formula = levelBis ~ ., family = binomial(link = "logit"),  
    data = gym)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.445e+01	1.141e+03	-0.021	0.983
age	-5.769e-03	1.616e-02	-0.357	0.721
genderMale	4.887e-01	6.055e-01	0.807	0.420
weight	-7.215e-03	4.543e-02	-0.159	0.874
height	-1.079e-01	4.165e+00	-0.026	0.979
bpm_ave	-5.649e-03	2.587e-02	-0.218	0.827
duration	3.462e+00	3.167e+00	1.093	0.274
calories	1.723e-03	4.357e-03	0.396	0.692
typeHIIT	-8.890e-02	3.441e-01	-0.258	0.796
typeStrength	2.677e-02	3.336e-01	0.080	0.936
typeYoga	2.881e-01	3.500e-01	0.823	0.410
fat	-2.750e-04	4.130e-02	-0.007	0.995
water	-2.717e-01	2.960e-01	-0.918	0.359
freq3	2.058e+01	1.141e+03	0.018	0.986
freq4	4.046e+01	1.482e+03	0.027	0.978
freq5	3.852e+01	2.043e+03	0.019	0.985
bmi	2.632e-02	1.389e-01	0.190	0.850

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1298.23 on 972 degrees of freedom
Residual deviance: 414.51 on 956 degrees of freedom
AIC: 448.51

Number of Fisher Scoring iterations: 19

En regardant les p-valeurs, on constate qu'aucune des variables n'est significative, ce qui est étrange car l'analyse descriptive montre que beaucoup de variables sont liées entre elles. En regardant de plus près, on constate que l'estimation et l'écart-type des fréquences est très important par rapport aux autres variables. Nous allons donc faire un modèle sans cette variable.

```
gym$freq <- NULL  
model_logit1<- glm(levelBis ~ ., data = gym, family = binomial(link = "logit"))  
summary(model_logit1)
```

```
Call:
glm(formula = levelBis ~ ., family = binomial(link = "logit"),
    data = gym)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.121e+01	5.654e+00	-1.982	0.04748	*
age	-1.447e-03	1.096e-02	-0.132	0.89500	
genderMale	-3.275e-01	3.716e-01	-0.881	0.37808	
weight	-6.062e-02	3.095e-02	-1.959	0.05015	.
height	4.883e+00	2.869e+00	1.702	0.08882	.
bpm_ave	-4.678e-03	1.700e-02	-0.275	0.78312	
duration	4.697e+00	1.997e+00	2.352	0.01868	*
calories	4.696e-04	2.750e-03	0.171	0.86443	
typeHIIT	-5.131e-02	2.360e-01	-0.217	0.82789	
typeStrength	1.694e-01	2.252e-01	0.752	0.45191	
typeYoga	3.656e-01	2.385e-01	1.533	0.12520	
fat	-7.614e-02	2.363e-02	-3.222	0.00127	**
water	-1.828e-01	1.989e-01	-0.919	0.35784	
bmi	1.987e-01	9.452e-02	2.102	0.03553	*

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1298.23 on 972 degrees of freedom
Residual deviance: 892.45 on 959 degrees of freedom
AIC: 920.45

Number of Fisher Scoring iterations: 6

On voit que les p-valeurs sont plus cohérentes car nous avons certaines variables qui sont explicatives et d'autres non. Pour faire le tri dans ces variables, nous allons procéder à une sélection de modèle par critère AIC.

```
choix=stepAIC(model_logit1,k=log(nrow(gym)),direction="backward")
```

Start: AIC=988.77

```
levelBis ~ age + gender + weight + height + bpm_ave + duration +
  calories + type + fat + water + bmi
```

	Df	Deviance	AIC
- type	3	896.07	971.76
- age	1	892.46	981.91
- calories	1	892.48	981.92
- bpm_ave	1	892.52	981.97
- gender	1	893.22	982.67
- water	1	893.29	982.74
- height	1	895.36	984.81
- weight	1	896.32	985.76
- bmi	1	896.92	986.36
- duration	1	898.02	987.46
<none>		892.45	988.77
- fat	1	903.39	992.83

Step: AIC=971.76

levelBis ~ age + gender + weight + height + bpm_ave + duration +
calories + fat + water + bmi

	Df	Deviance	AIC
- calories	1	896.08	964.88
- age	1	896.10	964.91
- bpm_ave	1	896.11	964.91
- gender	1	896.58	965.39
- water	1	897.14	965.95
- height	1	899.05	967.86
- weight	1	900.00	968.80
- bmi	1	900.54	969.34
- duration	1	902.07	970.88
<none>		896.07	971.76
- fat	1	907.10	975.91

Step: AIC=964.88

levelBis ~ age + gender + weight + height + bpm_ave + duration +
fat + water + bmi

	Df	Deviance	AIC
- bpm_ave	1	896.21	958.13
- age	1	896.22	958.15
- gender	1	896.76	958.69
- water	1	897.15	959.08
- height	1	899.07	961.00
- weight	1	900.03	961.95
- bmi	1	900.57	962.50

<none>		896.08	964.88
- fat	1	907.14	969.07
- duration	1	1142.30	1204.22

Step: AIC=958.13

levelBis ~ age + gender + weight + height + duration + fat +
water + bmi

	Df	Deviance	AIC
- age	1	896.37	951.41
- gender	1	896.89	951.93
- water	1	897.28	952.33
- height	1	899.20	954.25
- weight	1	900.14	955.18
- bmi	1	900.68	955.72
<none>		896.21	958.13
- fat	1	907.22	962.26
- duration	1	1142.39	1197.43

Step: AIC=951.41

levelBis ~ gender + weight + height + duration + fat + water +
bmi

	Df	Deviance	AIC
- gender	1	897.06	945.22
- water	1	897.47	945.64
- height	1	899.28	947.45
- weight	1	900.19	948.35
- bmi	1	900.73	948.90
<none>		896.37	951.41
- fat	1	907.35	955.52
- duration	1	1142.67	1190.83

Step: AIC=945.22

levelBis ~ weight + height + duration + fat + water + bmi

	Df	Deviance	AIC
- height	1	899.43	940.71
- water	1	899.84	941.13
- weight	1	900.54	941.82
- bmi	1	900.97	942.25
<none>		897.06	945.22
- fat	1	907.46	948.74

- duration 1 1158.39 1199.67

Step: AIC=940.71

levelBis ~ weight + duration + fat + water + bmi

	Df	Deviance	AIC
- weight	1	901.38	935.79
- water	1	901.57	935.97
- bmi	1	902.75	937.16
<none>		899.43	940.71
- fat	1	911.12	945.52
- duration	1	1158.61	1193.01

Step: AIC=935.79

levelBis ~ duration + fat + water + bmi

	Df	Deviance	AIC
- bmi	1	902.92	930.45
- water	1	905.53	933.05
<none>		901.38	935.79
- fat	1	911.81	939.33
- duration	1	1169.04	1196.56

Step: AIC=930.45

levelBis ~ duration + fat + water

	Df	Deviance	AIC
- water	1	906.38	927.02
<none>		902.92	930.45
- fat	1	914.16	934.80
- duration	1	1169.07	1189.72

Step: AIC=927.02

levelBis ~ duration + fat

	Df	Deviance	AIC
<none>		906.38	927.02
- fat	1	914.26	928.02
- duration	1	1176.54	1190.30

Cette procédure nous donne le modèle $Y_i = \beta_0 + \beta_1 x_{\text{fat},i} + \beta_2 x_{\text{duration},i}$.

```
model.aic <- glm(levelBis ~ fat + duration, data = gym, family = binomial(link = "logit"))
anova(model.aic,model_logit1)
```

Analysis of Deviance Table

Model 1: levelBis ~ fat + duration

Model 2: levelBis ~ age + gender + weight + height + bpm_ave + duration +
calories + type + fat + water + bmi

	Resid. Df	Resid. Dev	Df	Deviance	Pr(>Chi)
1	970	906.38			
2	959	892.45	11	13.936	0.2365

En réalisant un test de sous-modèle entre le résultat du choix par AIC et le modèle complet privé de level, on obtient une p-valeur de 0.2365, ce qui nous permet d'accepter le sous-modèle.